Αναζήτηση εικόνων με διανυσματικές αναπαραστάσεις

Μιχαήλ Ανδρουτσόπουλος (AM: sdi2200005)

Κωνσταντίνος Τσιότσιας (AM: sdi2300251)

Τμήμα Πληροφορικής και Τηλεπικοινωνιών
Εθνικό και Καποδιστριακό Πανεπιστήμιο Αθηνών (ΕΚΠΑ)

***Abstract*—Στη παρούσα εργασία υλοποιήθηκε, αυτοματοποιήθηκε και αξιολογήθηκε ένα ολοκληρωμένο σύστημα ανάκτησης εικόνων βασισμένο στη μέθοδο Bag-of-Visual-Words (BoVW) με τη χρήση SIFT descriptors και οπτικού λεξιλογίου εκπαιδευμένου μέσω k-means. Συγκρίθηκαν πέντε μέθοδοι αναζήτησης: η εξαντλητική αναζήτηση (Exact Search), οι προσεγγιστικές μέθοδοι Locality Sensitive Hashing (LSH) και Υπερκύβος (Hypercube), καθώς και οι μέθοδοι χωριστής ευρετηρίασης Inverted File Flat (IVF-Flat) και Product Quantization (IVF-PQ). Η αξιολόγηση πραγματοποιήθηκε στα σύνολα δεδομένων HPatches και MIRFlickr-25K ως προς την ακρίβεια (Recall@5, Recall@10, mAP@10) και τον χρόνο εκτέλεσης. Παράλληλα, αναλύθηκε εκτενώς η επίδραση των παραμέτρων εκτέλεσης (CLI arguments) και οι λόγοι απόκλισης της ακρίβειας μεταξύ των αλγορίθμων.**

***Index Terms*—Image Retrieval, SIFT, Bag-of-Visual-Words, k-means, LSH, Hypercube, IVF-Flat, IVF-PQ.**

I.

Η ανάκτηση παρόμοιων εικόνων σε μεγάλα ψηφιακά αποθέματα αποτελεί θεμελιώδες πρόβλημα στην υπολογιστική όραση. Η κλασική προσέγγιση Bag-of-Visual-Words (BoVW) μετατρέπει κάθε εικόνα σε ένα ιστόγραμμα συχνοτήτων οπτικών λέξεων (visual words), επιτρέποντας την εφαρμογή αλγεβρικών μετρικών απόστασης και προσεγγιστικών αλγορίθμων γειτονίας (Approximate Nearest Neighbor - ANN).

Σκοπός αυτής της εργασίας δεν είναι μόνο η ορθή αλγοριθμική υλοποίηση, αλλά η εις βάθος μελέτη του trade-off μεταξύ υπολογιστικής ταχύτητας και ακρίβειας ανάκτησης, αξιοποιώντας πραγματικά δεδομένα από το σύνολο HPatches και εικόνες θορύβου (distractors) από το MIRFlickr-25K.

II.

A. Εξαγωγή Χαρακτηριστικών και Οπτικό Λεξιλόγιο

Από κάθε εικόνα του training set εξάγονται έως $S = 500$ SIFT descriptors προκειμένου να αποφευχθεί η υπερσυγκέντρωση χαρακτηριστικών από πυκνές περιοχές. Στη συνέχεια, εφαρμόζεται προσαρμοσμένος αλγόριθμος k-means για την εύρεση $K = 256$ κέντρων ($c_1, \ldots, c_K \in \mathbb{R}^{128}$), τα οποία αποτελούν το κοινό οπτικό λεξιλόγιο για όλες τις εικόνες (training, validation, test και MIRFlickr).

Κάθε εικόνα I αναπαρίσταται από κανονικοποιημένο διάνυσμα πυκνότητας $x_I \in \mathbb{R}^K$, όπου οι συντεταγμένες αντιπροσωπεύουν το σχετικό πλήθος εμφάνισης κάθε οπτικής λέξης:

$$x_I = \left(\frac{h_1}{n_I}, \ldots, \frac{h_K}{n_I} \right), \quad n_I = \sum_{j=1}^{K} h_j \tag{1}$$

B. Αναλυτική Παρουσίαση των Μεθόδων Αναζήτησης

Για την ανεύρεση των $K = 10$ πλησιέστερων εικόνων σε κάθε query, υλοποιήθηκαν οι ακόλουθες πέντε μέθοδοι:

1) **Exact Search:** Υπολογισμός της Ευκλείδειας απόστασης L_2 με όλα τα στοιχεία της βάσης. Εγγυάται μέγιστη ακρίβεια αλλά εμφανίζει γραμμική πολυπλοκότητα $\mathcal{O}(N)$.
2) **LSH:** Αξιοποίηση τυχαίων προβολών και L πινάκων κατακερματισμού. Οι υποψήφιοι περιορίζονται στους κουβάδες που συμπίπτουν με το query.
3) **Hypercube:** Προβολή των διανυσμάτων στις κορυφές ενός υπερκύβου διάστασης d' ($kproj$). Η αναζήτηση επεκτείνεται σε γειτονικές κορυφές βάσει απόστασης Hamming.
4) **IVF-Flat:** Διαίρεση του χώρου σε συστάδες Voronoi μέσω k-means. Κατά το query, εξετάζονται αποκλειστικά οι $nprobe$ πλησιέστερες συστάδες.
5) **IVF-PQ:** Συνδυασμός Inverted File και Product Quantization. Τα διανύσματα διασπώνται σε M υποδιανύσματα και συμπιέζονται, επιτρέποντας ασύμμετρο υπολογισμό απόστασης (ADC) μέσω πινάκων Look-Up Tables (LUT).

III. (CLI SCRIPT)

Η εκτέλεση των πειραμάτων αυτοματοποιήθηκε πλήρως μέσω του συνοδευτικού shell script (`run_experiments.sh`), το οποίο διαχειρίζεται δυναμικά τα μεγέθη θορύβου $D \in \{1000, 5000, 10000, 25000\}$ και καλεί το εκτελέσιμο με συγκεκριμένα ορίσματα (arguments). Η επιλογή αυτών των παραμέτρων καθορίζει κρίσιμα χαρακτηριστικά απόδοσης:

- **Μέγεθος Λεξιλογίου (`-vocab 256`):** Ορίζει τη διάσταση του διανύσματος x_Q. Μεγαλύτερο λεξιλόγιο αυξάνει τη διακριτική ικανότητα των οπτικών λέξεων,

αυξάνοντας όμως το κόστος αποθήκευσης και υπολογισμού.

- **Παράμετροι LSH (`-k 4 -L 15 -w 0.1`):** Η αύξηση του πλήθους των πινάκων κατακερματισμού σε $L = 15$ διευρύνει την κάλυψη και μειώνει την πιθανότητα απόρριψης έγκυρων γειτόνων (false negatives), αυξάνοντας ωστόσο τον αριθμό των υποψήφιων buckets που ελέγχονται. Το πλάτος κελιού $w = 0.1$ καθορίζει το εύρος του κελιού προβολής.
- **Παράμετροι Hypercube (`-kproj 10 -M 500 -probes 100 -w 0.1`):** Η ρύθμιση `-probes 100` επιτρέπει την εξέταση έως 100 γειτονικών κορυφών στον υπερκύβο. Υψηλότερο πλήθος probes συγκλίνει τα αποτελέσματα προς την Exact Search αυξάνοντας τον χρόνο.
- **Παράμετροι IVF (`-nprobe 10, -M 16, -nbits 8`):** Το `-nprobe 10` καθορίζει τον αριθμό των Voronoi cells που σαρώνονται. Στο IVF-PQ, η διαίρεση σε $M = 16$ υποδιανύσματα με $nbits = 8$ συμπιέζει δραστικά τη μνήμη, επιτρέποντας αστραπιαίους υπολογισμούς.
- **Κλιμάκωση Θορύβου (`-D`):** Η προσθήκη εικόνων MIRFlickr λειτουργεί ως αποπροσανατολιστικός παράγοντας (distractors), αυξάνοντας τη δυσκολία ανάκτησης καθότι εισάγει ψευδώς θετικά αποτελέσματα (false positives) στον ίδιο μετρικό χώρο.

IV.

Τα πειράματα εκτελέστηκαν αυτοματοποιημένα και τα συνολικά στατιστικά συγκεντρώθηκαν στο αρχείο `ALL_RESULTS.txt`. Ο παρακάτω πίνακας παρουσιάζει τα συγκριτικά αποτελέσματα για μέγεθος βάσης $D = 10000$:

Table I
($D = 10000$)

Μέθοδος	Recall@5	Recall@10	mAP@10	Χρόνος (ms)
Exact Search	0.721	0.800	0.728	11.81
LSH	0.695	0.773	0.717	7.11
Hypercube	0.669	0.747	0.694	13.76
IVF-Flat	0.695	0.773	0.717	17.55
IVF-PQ	0.391	0.434	0.403	1.44

A. Ενδελεχής Ανάλυση των Λόγων Απόκλισης στην Ακρίβεια

Οι διαφορές στην ακρίβεια ανάμεσα στις μεθόδους δεν είναι τυχαίες, αλλά απορρέουν απευθείας από τους περιορισμούς των μηχανισμών ευρετηρίασης και προσέγγισης:

1) **Exact Search (To Upper Bound):** Επιτυγχάνει μέγιστη ακρίβεια (Recall@10 = 0.800) επειδή δεν παραλείπει κανένα διάνυσμα. Αποτελεί το σημείο αναφοράς (baseline), πληρώνοντας ωστόσο το τίμημα της γραμμικής πολυπλοκότητας.
2) **LSH και Hypercube (Προσεγγιστικός Κατακερματισμός):** Η απόδοσή τους υστερεί ελαφρώς εξαιτίας του φαινομένου της οριακής ασάφειας (boundary issue). Αν ένα διάνυσμα query βρίσκεται πολύ κοντά στα όρια ενός κελιού κατακερματισμού w ή μιας κορυφής του υπερκύβου, μικρές διακυμάνσεις το οδηγούν σε διαφορετικό bucket, χάνοντας τον αληθινό γείτονα. Στον Υπερκύβο, η προβολή σε χαμηλότερη διάσταση $d' = 10$ προκαλεί απώλεια ορισμένων τοπικών γεωμετρικών συσχετίσεων.
3) **IVF-Flat (Χωροταξική Ομαδοποίηση):** Η απόδοσή του προσεγγίζει την Exact Search διότι ο περιορισμός της αναζήτησης στις $nprobe$ πλησιέστερες συστάδες Voronoi καλύπτει το μεγαλύτερο εύρος πιθανών σχετικών εικόνων, αρκεί το $nprobe$ να μην είναι υπερβολικά μικρό.
4) **IVF-PQ (Σφάλμα Κβάντωσης και Ασυμμετρία):** Η αισθητή πτώση στο Recall@10 (0.434) και στο mAP@10 (0.403) οφείλεται στη συμπίεση των δεδομένων. Το Product Quantization τεμαχίζει τα διανύσματα και αντικαθιστά τα τμήματά τους με κέντρα κβάντωσης. Αυτό εισάγει εγγενές σφάλμα αναπαράστασης (quantization error), καθιστώντας δυσχερή τη διάκριση οριακών διανυσμάτων. Ωστόσο, η μέθοδος ανταμείβει με ασυναγώνιστη ταχύτητα (1.44 ms), καθιστώντας την ιδανική για τεράστιους όγκους δεδομένων όπου η ταχύτητα προηγείται της απόλυτης ακρίβειας.

V.

Η πειραματική μελέτη και η αυτοματοποιημένη εκτέλεση μέσω σεναρίου έδειξαν ότι η επιλογή της κατάλληλης μεθόδου αποτελεί μια ισορροπημένη απόφαση (trade-off) ανάμεσα στους περιορισμούς πόρων και τις απαιτήσεις ανάκτησης. Οι προσεγγιστικές μέθοδοι και οι δομές ευρετηρίασης καθίστανται μονόδρομος καθώς η βάση κλιμακώνεται με εικόνες θορύβου.